

МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ

Вознюк Анастасия Евгеньевна

**ПОСТРОЕНИЕ АНАЛИЗАТОРА ТЕКСТОВ С  
ПОМОЩЬЮ ДИСКУРСНЫХ ГРАФОВ**

01.03.02 — Информатика

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

**Научный руководитель:**

к. ф.-м. н. Андрей Грабовой

Москва — 2026

# Аннотация

# Содержание

|          |                                           |           |
|----------|-------------------------------------------|-----------|
| <b>1</b> | <b>Введение</b>                           | <b>4</b>  |
| <b>2</b> | <b>Моделирование связности текста</b>     | <b>5</b>  |
| <b>3</b> | <b>Использование подсчета сущностей</b>   | <b>7</b>  |
| 3.1      | Выделение паттернов . . . . .             | 9         |
| <b>4</b> | <b>Графы дискурсного анализа</b>          | <b>9</b>  |
| 4.1      | Формальная постановка . . . . .           | 10        |
| 4.2      | RST-дерево . . . . .                      | 11        |
| 4.2.1    | Глубина и ширина дерева . . . . .         | 12        |
| 4.2.2    | Матрица смежности RST-структуры . . . . . | 12        |
| 4.3      | Когерентность и RST-дерево . . . . .      | 13        |
| 4.3.1    | Структурная когерентность . . . . .       | 14        |
| <b>5</b> | <b>Постановка задачи</b>                  | <b>20</b> |
| <b>6</b> | <b>Методы детекции</b>                    | <b>21</b> |
| <b>7</b> | <b>Вычислительные эксперименты</b>        | <b>22</b> |
| <b>8</b> | <b>Заключение</b>                         | <b>23</b> |
|          | <b>Список литературы</b>                  | <b>24</b> |

# 1 Введение

Актуальность темы. Цели работы. Практическая значимость.

## 2 Моделирование связности текста

Связность текста определяется как характеристика текста, оценивающая насколько части текста связаны между собой. Связный текст позволяет читателю по ходу чтения видеть связи между сущностями в тексте и сразу получать цельную картину в голове о том, что он читает.

Мы можем оценить связность текста на двух уровнях: локальном и глобальном. Для оценки глобальной связности, мы оцениваем связность предложений или параграфов.

Теория связности изначально была введена в работе [1], и определяла три основных характеристики. Первой характеристикой является **связность** (cohesion), которая оценивает прямые и косвенные ссылки внутри текста между сущностями и идеями. Два основных условия:

Связность по ссылкам: Пара единиц текста  $(S_1, S_2)$  связаны по ссылкам, если в  $S_2$  упоминаются сущности из  $S_1$ :

*"Я люблю **яблоки**. Мой сын также **их** любит"*

Связность через семантический элемент: Пара единиц текста  $(S_1, S_2)$  связаны, если между ними существует семантическая ссылка, например причина-следствие или противопоставление:

*Шел дождь. **Поэтому** мы решили остаться дома.*

Эти ссылки могут быть как явными, так и скрытыми. Подробный анализ семантических (дискурсных) ссылок приведен в Главе [?].

Далее определяется **консистентность** (consistency), измеряющая уровень внутренних противоречий в тексте, а также его логичность. Формально, для набора текстовых единиц  $\{S_i\}_{i=0}^{N-1}$ , смысл каждой единицы должен быть консистентен со всеми предыдущими  $\{S_j\}_{j=0}^{i-1}$  и не нарушать предпосылки читателя и ограничения. Пример текста, который нарушает консистентность:

*Мой отец погиб пять лет назад. Именно поэтому я попросил его помочь мне с заданием сегодня вечером.*

Несмотря на то, что текст связан, он противоречит нашим знаниям о мире.

Наконец, также оценивается **релевантность** (relevance) частей текста задачам и целям, которые автор пытается достигнуть в своем тексте.

### 3 Использование подсчета сущностей

Подходы к моделированию локальной когерентности с использованием сущностей в тексте, являются достаточно классическими в лингвистике: ([2, 3, 4]). Большинство подходов исходят из одной общей предпосылки: когерентность явно связана с тем, как сущности вводятся и обсуждаются в тексте [5]. Предполагается, что тексты, в которых постоянно упоминаются схожие сущности, являются более когерентными, чем те, в которых происходит случайный и неожиданный переход от одной сущности к другой.

Barzilay и Lapata [5] предложили общий вычислительный подход к моделированию локальной когерентности, основанный на отношениях между сущностями в соседних предложениях. Предполагается, что распределение сущностей в когерентных текстах содержит определенные закономерности, которые могут быть отражены в “сетке сущностей” (entity grid).

В модели “сетки сущностей» каждый текст представляется в виде двумерного массива, строки которого соответствуют сущностям, а столбцы — предложениям. Элемент  $r_{i;j}$  в таблице описывает грамматическую роль сущности  $i$  в предложении  $j$ , если эта сущность упоминается в предложении. Грамматические роли классифицируются как подлежащее (субъект  $S$ ), дополнение (объект  $O$ ) или все остальные грамматические роли (иное,  $X$ ). Кроме того, если сущность не упоминается в предложении, соответствующая ячейка  $r_{i;j}$  заполняется специальным маркером (-). Наконец, если предложение содержит несколько упоминаний одной сущности, соответствующая ячейка описывает наиболее важную грамматическую роль из упоминаний в предложении: подлежащее, если возможно, затем дополнение, или, наконец, иную роль.

В примере на Рис. 1 и Рис. 2 приведен образец текста и построенной

по нему сетки сущностей. Именованные фразы выделены скобками, обозначающими упоминания. Упоминания в предложении соотносятся с их грамматическими ролями в предложении и обозначены буквой (S: подлежащее, O: дополнение и X: иное) рядом со скобками.

1 **[The Justice Department]**<sup>S</sup> is conducting an [anti-trust trial]<sup>O</sup> against [Microsoft Corp.]<sup>X</sup> with [evidence]<sup>X</sup> that [the company]<sup>S</sup> is increasingly attempting to crush [competitors]<sup>O</sup>.

2 **[Microsoft]**<sup>O</sup> is accused of trying to forcefully buy into [markets]<sup>X</sup> where [its own products]<sup>S</sup> are not competitive enough to unseat [established brands]<sup>O</sup>.

3 **[The case]**<sup>S</sup> revolves around [evidence]<sup>O</sup> of [Microsoft]<sup>S</sup> aggressively pressuring [Netscape]<sup>O</sup> into merging [browser software]<sup>O</sup>.

4 **[Microsoft]**<sup>S</sup> claims [its tactics]<sup>S</sup> are commonplace and good economically.

5 **[The government]**<sup>S</sup> may file [a civil suit]<sup>O</sup> ruling that [conspiracy]<sup>S</sup> to curb [competition]<sup>O</sup> through [collusion]<sup>X</sup> is [a violation of the Sherman Act]<sup>O</sup>.

6 **[Microsoft]**<sup>S</sup> continues to show [increased earnings]<sup>O</sup> despite [the trial]<sup>X</sup>.

Легенда:
 S субъект
 O объект
 X иное

Рис. 1: Пример текста, по которому строится entity grid. Текст взят из [5]

|   | Department | Trial | Microsoft | Evidence | Competitors | Markets | Products | Brands | Case | Netscape | Software | Tactics | Government | Suit | Earnings |   |
|---|------------|-------|-----------|----------|-------------|---------|----------|--------|------|----------|----------|---------|------------|------|----------|---|
| 1 | S          | O     | S         | X        | O           | —       | —        | —      | —    | —        | —        | —       | —          | —    | —        | 1 |
| 2 | —          | —     | O         | —        | —           | X       | S        | O      | —    | —        | —        | —       | —          | —    | —        | 2 |
| 3 | —          | —     | S         | O        | —           | —       | —        | —      | S    | O        | O        | —       | —          | —    | —        | 3 |
| 4 | —          | —     | S         | —        | —           | —       | —        | —      | —    | —        | —        | S       | —          | —    | —        | 4 |
| 5 | —          | —     | —         | —        | —           | —       | —        | —      | —    | —        | —        | S       | O          | —    | —        | 5 |
| 6 | —          | X     | S         | —        | —           | —       | —        | —      | —    | —        | —        | —       | —          | O    | —        | 6 |

---

Легенда: S субъект O объект X иное — нет ссылки

Рис. 2: Entity grid по тексту из Рис. 1. Пример взят из [5]



### 3.1 Выделение паттернов

Основная гипотеза модели “сетки сущностей” заключается в том, что как распределение сущностей, так и изменение грамматических ролей упоминаний сущностей в тексте демонстрируют схожие закономерности в связных текстах. Barzilay и Lapata [5] определяют все возможные переходы, которые могут происходить с сущностью в тексте, как закономерности, например {SO}, {OX}, {X-} и т.д..

## 4 Графы дискурсного анализа

Основным фокусом данной главы является дискурсивная структура текста. На данный момент есть работы, которые показывают, что трансформеры в текущем виде достаточно слабо понимают текст с этой точки зрения и не могут эффективно ее использовать для решения задач, в то время как сама по себе она является достаточно полезным инструментом анализа текстов [6, 7].

Теория риторических структур (RST) является одним из самых известных и популярных фреймворков, благодаря богатому выбору парсеров и датасетов, размеченных этими парсерами. В этом фреймворке предлагается описание организации текста как древовидной иерархической структуры, элементарные единицы которой объединены логическими отношениями, образуя более крупные единицы, которые в свою очередь связаны между собой теми же самыми отношениями, и так далее [8]. Авторы TRC вводят 23 дискурсивных отношения: одноядерные (бинарные отношения, в которых один элемент играет роль ядра, а другой - сателлита) и мультиядерные (отношения между двумя и более равнозначными элементами) [9]. Стоит отметить, что эти отношения были разработаны для английского языка и могут не так хорошо работать

для русского языка.

Разметка риторической структуры текста делится на два этапа: а) выделение элементарных дискурсивных единиц и б) установление отношений между ними.

## 4.1 Формальная постановка

Пусть текст  $T$  представлен как упорядоченная последовательность элементарных дискурсивных единиц (далее ЭДЕ). Это могут быть предложения или параграфы.

$$T = (e_1, e_2, \dots, e_N), \quad e_i \in \mathcal{E},$$

где  $\mathcal{E}$  – множество всех возможных ЭДЕ. Сама ЭДЕ определяется следующим образом:

$$e_i = (s_i, \phi_i, \mathbf{v}_i),$$

где  $s_i$  – текстовый спан ЭДЕ,  $\mathbf{v}_i \in \mathbb{R}^d$  – векторное представление. Предикат  $\phi_i : W^* \rightarrow \{0, 1\}$  выполняет роль Только те фрагменты  $s_i$ , для которых верно, что  $\phi_i = 1$ , принимаются как ЭДЕ. Неформально, это используется, чтобы определить, верно ли, что этот фрагмент текста достаточно самостоятелен, чтобы что-то утверждать о мире. Примеры ЭДЕ и значений  $\phi$  представлены в Таблице 1.

Далее, определим конечное множество отношений между ЭДЕ. Перед началом работы мы фиксируем допустимые риторические отношения:

$$\mathcal{R} = \{r_1, \dots, r_k\}$$

.

В классической англоязычной RST-теории  $|\mathcal{R}| = 23$ , для русского языка это число было адаптировано  $|\mathcal{R}| = 21$ [\[9\]](#).

| Фрагмент                   | $\phi$ | Объяснение                                          |
|----------------------------|--------|-----------------------------------------------------|
| Эксперимент был остановлен | 1      | Есть предикат (остановлен) и субъект (эксперимент)  |
| после того как             | 0      | Только коннектор,<br>нет ни предиката, ни аргумента |
| из-за резкого              | 0      | Оборван, предикат отсутствует                       |
| результаты незначимы       | 1      | Полная пропозиция                                   |
| что подтверждает           | 0      | Предикат есть, но субъекта нет                      |

Таблица 1: Примеры допустимых ( $\phi = 1$ ) и недопустимых ( $\phi = 0$ ) ЭДЕ.

Для каждого  $r_i \in \mathcal{R}$  определим **эффект**:

$$\text{Effect}_{r_i} : \mathcal{E} \times \mathcal{E} \rightarrow [0, 1],$$

показывающую, насколько применение отношения  $r_i$  к паре  $(e_i, e_j)$  достигает коммуникативной цели.

Как уже было упомянуто раньше, в RST-теории существуют два типа отношения: одноядерные и мультиядерные. Одноядерное отношение  $r(N, S)$  асимметрично и состоит из ядра  $N$ , и сателлита  $S$ , удаление сателлита не разрушает смысл пары, удаления ядра – нарушает. Второй тип это мультиядерное отношение  $r(N_1, N_2)$  – все единицы симметричны по важности.

## 4.2 RST-дерево

**Определение 1:** RST-дерево для текста  $T = \langle e_1, e_2, \dots, e_n \rangle$  – это помеченное бинарное или  $k$ -арное дерево  $\mathcal{T} = (V, E, \lambda, \rho)$ , где

- $V$  - множество узлов, это наши ЭДЕ;

- $E \subseteq V \times V$  – ребра задающие наши отношения;
- $\lambda : V \rightarrow 2^{\{1,2,\dots,n\}}$  - функция, сопоставляющая каждому узлу множество охватываемых им ЭДЕ (спан);
- $\rho : E \rightarrow \mathcal{R} \times \{N,S\}^2$

Для листьев дерева  $l \in L \subseteq V : \lambda(l) = \{i\}$  для некоторого  $i$ , т.е. каждый лист соответствует ровно одной ЭДЕ. Для внутреннего узла  $v$  :

$$\lambda(v) = \bigcup_{u \in \text{children}(v)} \lambda(u), \quad \lambda(v_1) \cap \lambda(v_2) = \emptyset \quad \forall v_1 \neq v_2$$

Корень  $r_0 \in V$  охватывает весь текст:  $\lambda(r_0) = \{1, \dots, n\}$ .

#### 4.2.1 Глубина и ширина дерева

Определим глубину узла  $v$  :

$$\text{depth}(v) = \begin{cases} 0 & v = r_0 \\ \text{depth}(\text{parent}(v)) + 1 & \text{иначе} \end{cases}$$

Максимальная глубина дерева:  $D(\mathcal{T}) = \max_{l \in L} \text{depth}(l)$ . Средняя глубина листьев (мера структурной сложности):

$$\bar{D}(\mathcal{T}) = \frac{1}{n} \sum_{l \in L} \text{depth}(l)$$

#### 4.2.2 Матрица смежности RST-структуры

Введём матрицу риторических отношений  $A \in \mathbb{R}^{n \times n}$  :

$$A_{ij} = \begin{cases} w(r) & \text{если существует отношение } r(e_i, e_j) \text{ в } \mathcal{T} \\ 0 & \text{иначе} \end{cases}$$

где  $w : \mathcal{R} \rightarrow (0,1]$  - весовая функция, отражающая силу риторической связи:

$$w(r) = \frac{\text{freq}(r)}{\sum_{r' \in \mathcal{R}} \text{freq}(r')} \cdot \alpha_r$$

### 4.3 Когерентность и RST-дерево

Через RST-дерево  $\mathcal{T}$  можно оценить несколько аспектов когерентности текста. Во-первых, риторическая структура когерентного текста насыщена разнообразными отношениями и эти отношения равномерно распределены по тексту. Если наблюдается преобладание лишь нескольких типов связи (например, только Elaboration), это сигнализирует о монотонности и скудности изложения, в то время как большое разнообразие отношений между единицами текста говорит о полноценной развёрнутой аргументации. Во-вторых, риторические связи должны быть локальными: если два сегмента  $e_i, e_j$  связаны некоторым отношением  $r \in \mathcal{T}$  но при этом

$$r(e_i, e_j) \in \mathcal{T}, |i - j| > \alpha,$$

то такая пара является **разорванной** — между связанными единицами располагается значительное число посторонних сегментов. Отметим, что порог  $\alpha$  не является универсальным и варьируется от текста к тексту в зависимости от его длины и жанра. Наличие разорванных пар означает, что читателю приходится удерживать в рабочей памяти незавершённую риторическую связь на протяжении нескольких промежуточных единиц — что увеличивает когнитивную нагрузку и снижает воспринимаемую связность текста. Таким образом, когерентный текст стремится к минимизации как числа разорванных пар, так и величины разрыва  $|i - j|$ .

Формально, рассмотрим три метрики, которые формализуют описанные

выше требования к тексту.

### 4.3.1 Структурная когерентность

Первый критерий качества оценивает насколько иерархия риторических отношений представляет собой связную и сбалансированную структуру без вырожденных внутренних узлов. Так как внутренние узлы представляют риторические отношения, они всегда должны объединять минимум два сегмента (левый и правый аргумент отношения). Ситуация когда внутренний узел имеет одного потомка (самого себя) означает транзитный узел без риторического смысла. В тексте таких вырожденных узлов должно содержаться по минимуму, их доля снижает структурную когерентность. Мы представим три способа оценивать иерархию, проведем анализ и несколько теорем.

Для начала рассмотрим три различных текста и посмотрим для них RST-дерево с помощью библиотеки `isanlp_rst` [10]:

**Текст 1:** “Регулярные физические упражнения укрепляют иммунную систему. Это происходит потому, что умеренная нагрузка стимулирует выработку лейкоцитов. В частности, уже 30 минут ходьбы в день повышают активность НК-клеток. Поэтому люди, занимающиеся спортом регулярно, болеют простудой в среднем на 40% реже.”

В данном тексте есть достаточно логичное и классическое развитие аргументации в формате “тезис  $\rightarrow$  аргумент  $\rightarrow$  аргумент 2  $\rightarrow$  пример”. Нет вырожденных узлов, так как каждый внеутренний узел объединяет ровно двух потомков. Формально, здесь есть 4 ЭДЕ, каждая из которых подчиняет собой следующую со следующими отношениями: Evidence  $\rightarrow$  Cause-effect  $\rightarrow$  Elaboration.

Следующий текст выражает собой списковый текст с перечислением равноправных фактов без какой-либо иерархии и объемной риторической




Рис. 3: RST-дерево для связного текста.

структуры.

**Текст 2:** “Спорт укрепляет сердечно-сосудистую систему. Спорт снижает уровень стресса. Спорт помогает поддерживать нормальный вес. Спорт улучшает качество сна.”




Рис. 4: RST-дерево для текста-списка.




Рис. 5: RST-дерево для текста-списка.

Парсинг данного текста даст плоское дерево.<sup>1</sup> Все ЭДЕ в таком тексте равноправны. Формально все отношения будут заданы как Joint.

Наконец, третий текст представляет собой смешанную структуру.

**Текст 3:** “Спорт полезен для большинства людей. Многие ходят в спортзал. Однако некоторым спорт противопоказан. Например, при определённых заболеваниях сердца.”

Обозначим  $\text{Ch}(v) \subseteq V$  за множество всех потомков вершины  $v$ . Пусть  $L \subset V$  – множество листьев для дерева  $\mathcal{T}$ , а за  $\text{int}(V) = V \setminus L$  обозначим за множество внутренних узлов.

Введем количество вырожденных узлов:

$$C_s(\mathcal{T}) = 1 - \frac{|\{v \in \text{int}(V) : |\text{Ch}(v)| = 1\}|}{|\text{int}(V)|} \quad (1)$$

где  $C_s(\mathcal{T}) = 1$  обозначает “идеальную” структуру, где все внутренние узлы бинарные или  $k$ -арные, а  $C_s(\mathcal{T}) = 0$  выражает вырожденное дерево. Заметим, что  $C_s(\mathcal{T})$  нечувствительна к тому какие отношения используются и насколько глубоко дерево, поэтому будем ее рассматривать как нижнюю оценку качества

<sup>1</sup>Парсер выдает именно плоское дерево из одного узла Joint с nuclearity: 'NN'. Так как визуализатор требует как минимум один nucleus-satellite сплит в заголовке, мы добавили искусственное разделение чтобы получить визуализацию.



парсинга. На основе этой метрики введем следующую величину, использующую взвешивание по глубине:

$$C_S^{\text{depth}}(\mathcal{T}) = 1 - \frac{\sum_{v \in \text{int}(V), |\text{ch}(v)|=1} w(\text{depth}(v))}{\sum_{v \in \text{int}(V)} w(\text{depth}(v))}, \quad w(d) = \frac{1}{d+1} \quad (2)$$

Мотивация такой метрики: так как вырожденный узел у корня хуже, чем на листовом уровне — он “портит” больше структуры, поэтому будем штрафовать вырождение обратно пропорционально глубине. Дополнительно введем учет степени ветвления:

$$C_S^{\text{branch}}(\mathcal{T}) = \frac{1}{|\text{int}(V)|} \sum_{v \in \text{int}(V)} \left( 1 - \frac{1}{|\text{Ch}(v)|} \right) \quad (3)$$

## Семантическая связность ребер

Определим рекурсивный вес нуклеарности для ЭДЕ:

$$\text{Nuc}(e_i) = \sum_{v \in \text{path}(e_i \rightarrow r_0)} 1 [\nu(e_i, v) = N] \cdot \gamma^{\text{depth}(v)} \quad (4)$$

где  $\text{path}(e_i, r_0)$  - путь от листа  $e_i$  до корня,  $\gamma \in (0,1)$  - коэффициент дисконтирования (обычно  $\gamma = 0.9$ ).

Нормированная важность:

$$\hat{\text{Nuc}}(e_i) = \frac{\text{Nuc}(e_i)}{\sum_{j=1}^n \text{Nuc}(e_j)}$$

Вектор  $\hat{\text{Nuc}} = (\hat{\text{Nuc}}(e_1), \dots, \hat{\text{Nuc}}(e_n))$  образует ядерную пирамиду текста и используется, в частности, в задаче автоматического реферирования.




Рис. 6: Приме

## Разрывность текста

Связь Same-unit не является риторическим отношением в строгом смысле — она фиксирует случаи, когда одна ЭДЕ физически разрывается вставным сегментом. Наличие таких разрывов само по себе не свидетельствует о некогерентности: вставка, поясняющая или уточняющая прерванную единицу, когнитивно ожидаема и не затрудняет понимание. Напротив, вставка риторически автономная — оценочная, интерпретирующая — прерывает линейное развёртывание мысли неожиданным образом и создаёт дополнительную когнитивную нагрузку. Пример:

*Министр, выступая перед журналистами, отказался комментировать ситуацию.*

*Компания объявила — впрочем, это всех удивило — о рекордной прибыли.*

Второй критерий помогает оценить качество отдельных рёбер. Мы стремимся к дереву с семантически связанными ЭДЕ, которые к тому же соединены риторическими отношениями где это необходимо. Мы оцениваем это с помощью тематической когерентности  $C_T^{RST}$  и ядерная пирамида  $\hat{Nuc}$ .

Наконец, соответствие между линейным порядком текста и его риторической структурой: наличие разрывов, при которых одна ЭДЕ физически прерывается вставным сегментом. Этот аспект фиксирует метрика  $C_{SU}$ , опирающаяся на риторический тип вставки.

Совместно три уровня анализа охватывают когерентность как на уровне целого текста, так и на уровне локальных связей между соседними единицами.

## 5 Постановка задачи

## 6 Методы детекции

## 7 Вычислительные эксперименты

## 8 Заключение

## Список литературы

1. *Reinhart Tanya*. Conditions for Text Coherence // *Poet. Today*. — 1980. — Vol. 1, no. 4. — P. 161.
2. *Halliday M.A.K., Hasan Ruqaiya*. Cohesion in English. — Routledge, 2014. — . — URL: <http://dx.doi.org/10.4324/9781315836010>.
3. *Prince Ellen F.* Toward a taxonomy of given-new information // Syntax and semantics: Vol. 14. Radical Pragmatics / Ed. by P. Cole. — New York: Academic Press, 1981. — Pp. 223–255.
4. *Grosz Barbara J., Joshi Aravind K., Weinstein Scott*. Centering: A Framework for Modeling the Local Coherence of Discourse // *Computational Linguistics*. — 1995. — Vol. 21, no. 2. — Pp. 203–225. — URL: <https://aclanthology.org/J95-2003/>.
5. *Barzilay Regina, Lapata Mirella*. Modeling Local Coherence: An Entity-Based Approach // *Computational Linguistics*. — 2008. — Vol. 34, no. 1. — Pp. 1–34. — URL: <https://aclanthology.org/J08-1001/>.
6. DiscSense: Automated Semantic Analysis of Discourse Markers / Damien Sileo, Tim Van de Cruys, Camille Pradel, Philippe Muller // Proceedings of the Twelfth Language Resources and Evaluation Conference / edited by Nicoletta Calzolari, Frédéric Béchet, Philippe Blache et al. — Marseille, France: European Language Resources Association, 2020. — . — Pp. 991–999. — URL: <https://aclanthology.org/2020.lrec-1.125/>.
7. *Koto Fajri, Lau Jey Han, Baldwin Timothy*. Discourse Probing of Pretrained Language Models // Proceedings of the 2021 Conference of the North American



- Chapter of the Association for Computational Linguistics: Human Language Technologies / Ed. by Kristina Toutanova, Anna Rumshisky, Luke Zettlemoyer et al. — Online: Association for Computational Linguistics, 2021. — . — Pp. 3849–3864. — URL: <https://aclanthology.org/2021.naacl-main.301/>.
8. *Mann William C., Thompson Sandra A.* Rhetorical Structure Theory: Toward a functional theory of text organization // *Text - Interdisciplinary Journal for the Study of Discourse*. — 1988. — Vol. 8, no. 3. — URL: <http://dx.doi.org/10.1515/text.1.1988.8.3.243>.
  9. *Ananyeva M. I. Kobozeva M. B.* Developing the corpus of Russian texts with markup based on the Rhetorical Structure Theory // Proceedings of the International Conference 'Dialogue 2016'. — Moscow: 2016. — . — URL: <http://www.dialog-21.ru/media/3460/ananyeva.pdf>.
  10. *Chistova Elena.* Bilingual Rhetorical Structure Parsing with Large Parallel Annotations // Findings of the Association for Computational Linguistics ACL 2024. — Bangkok, Thailand and virtual meeting: Association for Computational Linguistics, 2024. — . — Pp. 9689–9706. — URL: <https://aclanthology.org/2024.findings-acl.577>.