

Автоматический анализ текстов с помощью графовых представлений

Анастасия Евгеньевна Вознюк
Научный руководитель: к.ф.-м.н. А. В. Грабовой

Кафедра интеллектуальных систем ФПМИ МФТИ
Специализация: Интеллектуальный анализ данных

20 декабря 2025

Цель работы

Исследуется проблема оценки семантического качества текста, насколько он информативен и логически выстроен.

Цель исследования:

Предлагается исследовать методы автоматического анализа текста

Предлагаемый метод решения:

Представить текст в виде графа, где вершины графа – семантические единицы и провести анализ этого графа.

Общая постановка задачи

Пусть $\mathbf{W}$ — пространство текстовых единиц. Элемент $t_i \in \mathbf{W}$ может соответствовать слову, предложению, абзацу или иной минимальной единице анализа.

Тогда текстовый документ представляется как конечную последовательность единиц текста. Пространство документов:

$$\mathbb{D} = \left\{ \left[t_j \right]_{j=1}^n \mid t_j \in \mathbf{W}, n \in \mathbb{N} \right\}.$$

Каждому документу $d \in \mathbb{D}$ сопоставляется множество вершин

$$V_d := \{1, \dots, n\},$$

а также отображение разметки:

$$\tau_d : V_d \rightarrow \mathbf{W}, \quad \tau_d(j) = t_j,$$

которое сопоставляет вершинам соответствующие текстовые единицы.

Правило построения связей и граф по тексту.

Пусть задано множество типов отношений между единицами текста $\mathbf{R}$ (например, дискурсивные, тематические и т.д.).

Связи между текстовыми единицами определяются отображением

$$\varphi : \mathbf{W} \times \mathbf{W} \rightarrow 2^{\mathbf{R}},$$

где $\varphi(x, y)$ — множество типов отношений, связывающих единицы x и y .

Граф, соответствующий документу d , определяется как размеченный ориентированный граф

$$G_d = (V_d, E_d, \lambda_d),$$

где множество рёбер

$$E_d := \{(i, j) \in V_d \times V_d \mid \varphi(t_i, t_j) \neq \emptyset\},$$

а функция разметки рёбер $\lambda_d : E_d \rightarrow 2^{\mathbf{R}}$ задаётся как $\lambda_d(i, j) := \varphi(t_i, t_j)$.

Частные случаи графов

Тематический граф. Пусть $\mathbf{Z}$ — пространство тем, и θ — отображение, сопоставляющее текстовой единице множество тем.

$$\theta : \mathbf{W} \rightarrow 2^{\mathbf{Z}}$$

Тогда тематическая связь определяется как

$$\varphi_{\text{topic}}(x, y) := \theta(x) \cap \theta(y).$$

Дискурсивный граф. Пусть $\mathbf{S}$ — множество дискурсивных отношений, и δ — модель дискурсивной аннотации.

$$\delta : \mathbf{W} \times \mathbf{W} \rightarrow 2^{\mathbf{S}}$$


Тогда

$$\varphi_{\text{disc}}(x, y) := \delta(x, y).$$

Возможные направления анализа

1. Семантический анализ текста
 - 1.1 Анализ смысловой близости предложений и абзацев
2. Анализ логической связности
 - 2.1 Оценка внутренних противоречий в рассуждениях
 - 2.2 Выявление нарушений причинно-следственных связей
3. Лексический анализ текста
 - 3.1 Анализ лексической консистентности
 - 3.2 Оценка избыточности и повторяемости лексики
4. Тематический анализ текста
 - 4.1 Анализ частоты и резкости сменяемости тем внутри текста

Вид графа логической связности



Используется упрощенный набор связей: evidence, cause-eff, contrast, elaboration and joint (нет связи). Вершины упорядочены вдоль разметки.

Структурные признаки для анализа графа логической связности

Global Connectivity

плотность графа $|E|/|V|$

$\Pr(\deg^- > 0)$

компонент связности

диаметр

Argumentative Structure

доля(*evidence*, *cause*)

отношение *evidence/elaboration*

индикатор наличия центрального тезиса в виде среднего PageRank

Discourse Flow

доля ребер(forward edges)

“длинных” прыжков через ребра: $|i - j| > \tau$

энтропия распределения типов связей

Local Defects

изолированных вершин

максимальная длина цепочки без связи *evidence*

Вычислительный эксперимент

Логические связи между единицами текста протраиваются с помощью инструмента RST Parcer. На основе этих связей строится граф, по которому получаются структурные признаки. Для оценки этих признаков по графу и выдачи итогового качества использовался случайный лес. Данные были собраны наполовину вручную, часть взята из открытых датасетов, часть текстов из датасетов с текстами на русском языке, написанными не носителями языка.

Метод	MSE	R ²
Lexical Baseline	0.76	0.68
Semantic Baseline	0.69	0.56
Graph Analysis	0.36	0.85

Таблица: Сравнение результатов трех методов

К достоинствам метода можно также отнести высокий уровень интерпретируемости, а также гибкость настройки.

Тематический анализ текста

Для анализа частоты сменяемости тем был адаптирован метод сегментации текста на фрагменты, но с учетом тематических профилей всего документа и сегментов.

1. **Topic Coherence (C_v)** — измеряет семантическую согласованность слов внутри темы;
2. **Topic Diversity** — доля уникальных слов среди топ-слов всех тем;
3. **Количество тем** — число автоматически выделенных тематических кластеров;
4. **WinDiff** — разница в целевой и предложенной разметке.

Датасет	Число тем	C_v	Topic Diversity	WinDiff
PhilPapersAI	9	0.61	0.87	0.54
Abstracts	10	0.57	0.85	0.45

Итоги НИР за семестр и планы на следующий семестр

Результаты

1. Принята 1 работа на смежную тему по обработке логических связей на A* конференцию по обработке естественного языка;
2. Проведены эксперименты с автоматическим анализом текстов с помощью графов и начата работа над имплементацией полноценного фреймворка;
3. Проведены эксперименты для тематического модуля;

Публикации в текущем семестре

1. Quantifying logical consistency in transformers via query-key alignment. *2025 Conference on Empirical Methods in Natural Language Processing*